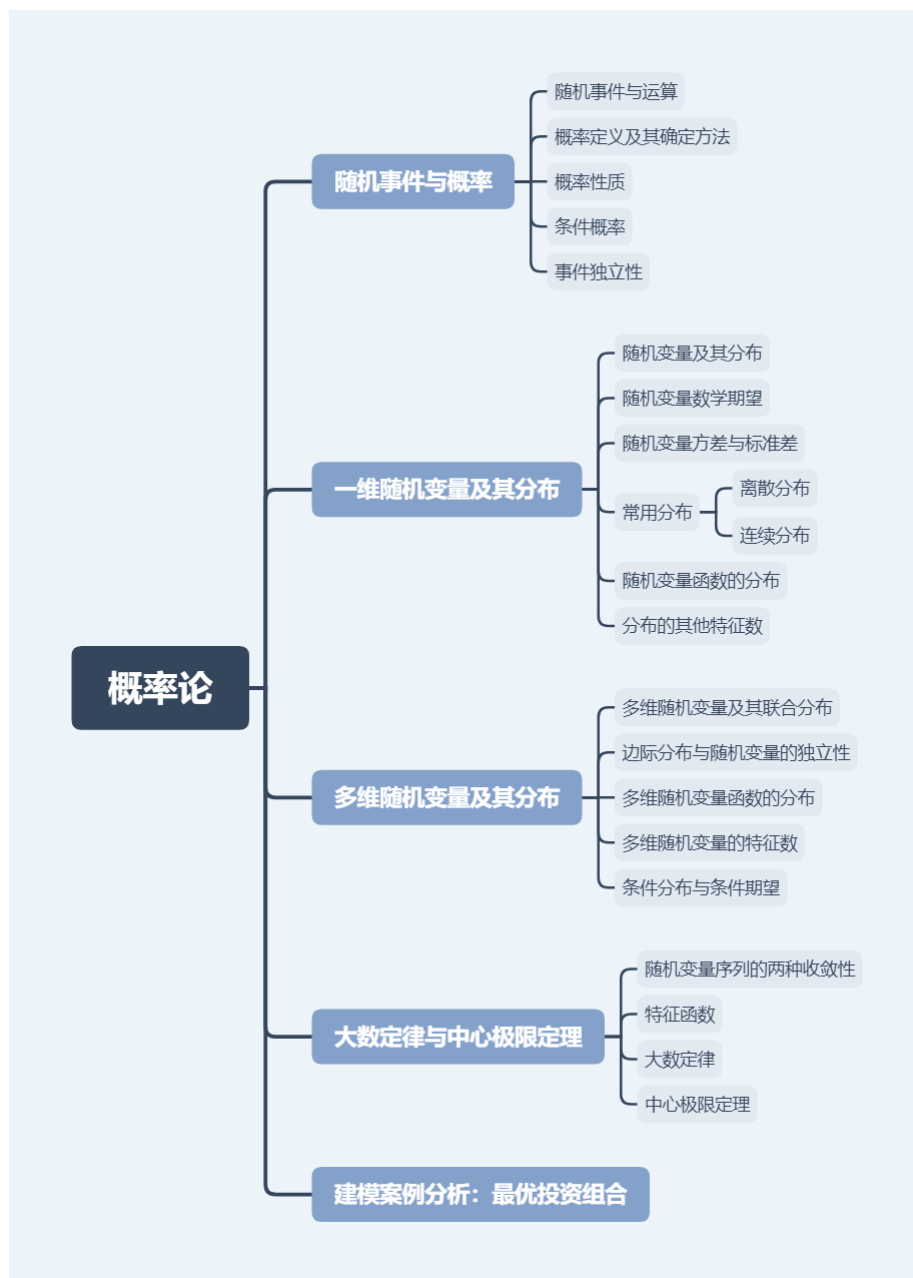


动手学概率论

这是一个关于数学建模相关理论知识的复习专题，同时记录在Datawhale社群的第二次打卡活动，从理论到python实践，课程参考 https://github.com/Git-Model/___init___Modeling___

在复习完高数、线代后，我们再来回顾一下概率论的内容。在大学的时候，我们会有一门《概率论与数理统计》的课程，简单来说，概率论与数理统计研究的对象是随机现象，而概率论主要研究的是随机现象的模型(即概率分布)及其性质，数理统计则是研究随机现象的数据收集、处理及统计推断，本文我们将参考茆诗松的《概率论与数理统计教程》，先来复习概率论部分的知识，主要内容如下：



✧ 1. 随机事件与概率

1.1. 随机事件及其运算

1.1.1. 随机现象

在一定条件下,并不总是出现相同结果的现象。如抛一枚硬币与掷一颗骰子,随机现象有两个特点:

- 结果不止一个

- 哪一个结果出现，人们事先不知道。

与之相对的，只有一个结果的现象称为确定性现象，我们前面高数部分的确定性的函数关系就可以用来表示这类现象。对于随机现象，我们如何才能得到某一种可能对应的结果出现的可能性大小呢？最简单的方式就是做实验。对于相同条件下可以重复的随机现象的观察、记录、实验称为随机试验，当然我们也要注意研究不能重复的随机现象。

1.1.2. 样本空间

随机现象的一切可能基本结果组成的集合称为样本空间，记为 $\Omega = \{\omega\}$ ，其中 ω 表示基本结果，又称为样本点。需要注意的是：

- 样本空间中的元素可以是数也可以不是数(比如硬币的正反)
- 随机现象的样本空间至少有两个样本点(只有一个样本点属于确定性现象)
- 样本点的个数为有限个或者可列的，称为离散样本空间；样本点个数为不可列无限个的，称为连续样本空间(比如掷硬币的结果，一台电视的寿命)

1.1.3. 随机事件与随机变量

随机现象的某些样本点组成的集合称为随机事件，简称事件，通常用 A, B, C, \dots 表示。如在抛一颗骰子时，“出现奇数点”是一个事件，它是由1点、3点、5点三个基本结果组成，若记这个事件为 A ，则有 $A = \{1, 3, 5\}$ ，它是相应样本空间 $\Omega = \{1, 2, 3, 4, 5, 6\}$ 的一个子集。

由样本空间 Ω 中的单个元素组成的子集称为基本事件，而样本空间 Ω 的最大子集(即 Ω 本身)称为必然事件，样本空间 Ω 的最小子集(即空集 ϕ)表示。

用来表示随机现象结果的变量称为随机变量，常用大写字母 X, Y, Z 表示，随机变量的含义往往要结合情景。比如：

很多随机现象的结果本身就是数，比如抛一颗骰子，可能出现1, 2, 3, 4, 5, 6。若设置 $X =$ “掷一颗骰子出现的点数”，则1, 2, 3, 4, 5, 6就是随机变量 X 的可能取值，这时

- 事件“出现3点”可用“ $X = 3$ ”表示
- 事件“出现点数超过3”可用“ $X > 3$ ”表示
- “ $X \leq 6$ ”是必然事件
- “ $X = 7$ ”是不可能事件

在这个随机现象中，可以再设 $Y =$ “掷一颗骰子6点出现的次数”，则 Y 是仅取0或1两个值的随机变量，这时

- “ $Y = 0$ ”表示事件“没有出现6点”
- “ $Y = 1$ ”表示事件“出现6点”
- “ $Y \leq 1$ ”是必然事件
- “ $Y \geq 2$ ”是不可能事件


当然还有一些随机现象结果不是数，但是仍然可以设计出有意义的随机变量，比如检验一个产品的可能结果有两个：合格和不合格。我们可以设置 $X =$ “检查一件产品所得的不合格产品数”， X 是仅取0或1两个值的随机变量，且“ $X = 0$ ”表示事件“出现合格品”，“ $X = 1$ ”表示事件“出现不合格品”。

1.1.4. 事件间的关系

下面的假设在同一个样本空间 Ω (即同一个随机现象)中进行，事件间的关系与集合间的关系一样，主要有以下几种：

H5 1. 包含关系

如果属于 A 的样本点必属于 B ，则称 A 被包含于 B 中，记为 $A \subset B$ 或 $B \supset A$ ，这时事件 A 发生必然导致事件 B 发生。对任一事件 A ，必有 $\phi \subset A \subset \Omega$ 。我们可以用Venn图来表示：用一个长方形来表示样本空间 Ω ，用圆来表示某个事件，当子集 A 中某个样本点出现了，就说事件 A 发生了。




H5 2. 相等关系

如果属于 A 的样本点属于 B ，同时属于 B 的样本点也必属于 A ，即 $A \subset B$ 且 $B \subset A$ ，那么就称 A 与 B 相等，记为 $A = B$ 。

H5 3. 互不相容

如果 A 与 B 没有相同的样本点，则称 A 与 B 互不相容，从概率论的角度来说，就是事件 A 与事件 B 不能同时发生。




1.1.5. 事件间的运算

事件的运算与集合的运算一致，有并、交、差和余四种运算。

H5 1. 并运算

由事件 A 与事件 B 中所有样本点组成的新事件，记为 $A \cup B$ ，此时“ A 与 B 中至少有一个会发生”。在掷一颗骰子的试验中，事件 $A=$ “出现奇数点” $=\{1, 3, 5\}$ 与事件 $B=$ “出现点数不超过3” $=\{1, 2, 3\}$ 的并为 $A \cup B = 1, 2, 3, 5$ 。 ，这里我们可以看到并集是会去重的。



H5 2. 交运算

由事件 A 与事件 B 中公共样本点组成的新事件，记为 $A \cap B$ ，此时“ A 与 B 同时发生”。对应上面Venn图中深绿色的部分。若事件 A 与事件 B 互不相容，则其交必为不可能事件，即 $AB = \phi$ 。

H5 3. 差运算

由在事件 A 中而不在事件 B 中的样本点组成的新事件，记为 $A - B$ ，此时“事件 A 发生而事件 B 不发生”。事件 A 的对立事件，记为 \bar{A} ，即“由在 Ω 中而不在 A 中的样本点组成的新事件”。 A 与 B 互为对立的充分必要条件是： $A \cap B = \phi$ ，且 $A \cup B = \Omega$ 。

1.2. 概率的定义及其确定方法

概率是随机事件发生的可能性大小。虽然随机事件的发生是带有偶然性的，但是其发生的可能性是可以度量的。在概率论发展历史上，曾有过概率的古典定义、概率的几何定义、概率的频率定义来对某一类随机现象定义概率。通过概率的公理化定义，可以给出适合一切随机现象的概率的最一般的定义。

1.2.1. 概率的公理化定义


在一个随机现象中，用来表示任意一个随机事件 A 发生可能性大小的实数，称为概率，记为 $P(A)$ ，其满足：

- 非负性公理： $P(A) \geq 0$
- 正则性公理：样本空间 Ω 的概率 $P(\Omega) = 1$
- 可加性公理：若 A_1 与 A_2 互不相容，则有 $P(A_1 \cup A_2) = P(A_1) + P(A_2)$

1.2.2. 确定概率的方法

H5 1. 频率法

频率法就是在大量重复实验中，用频率的稳定值当作概率，即 $f_n(A) = \frac{n(A)}{n}$ 。我们通过模拟，使用频率来度量 n 次投掷硬币，正面为1的概率。



H5 2. 古典法

古典法的基本思想如下：

- 所涉及到的随机现象只有有限个样本点，譬如 n 个
- 每个样本点发生的可能性相等(等可能性)
- 若事件 A 含有 k 个样本点，那么事件 A 的概率为

$$P(A) = \frac{\text{事件}A\text{所含样本点的个数}}{\Omega\text{中所有样本点的个数}} = \frac{k}{n}$$

古典概型一般会涉及到排列组合问题，因为我们需要找到样本空间以及事件 A 中所有的样本数，这里我们通过一个例子来进行说明：假设有 n 个球，每个球都等可能地被放到 N 个不同的盒子中的任一个，每个盒子所放球数不同，试求：

(1) 指定的 $n(n \leq N)$ 个盒子中各有一球的概率 p_1 ； (2) 恰好有 $n(n \leq N)$ 个盒子各有一球的概率。

解析：因为每个球都可放到 N 个盒子中的任一个且每个盒子可以放多个球，所以 n 个球的方法共有 N^n 种。

(1) 因为指定了 n 个盒子放球，所以其实我们只需要考虑 n 个球在指定的 n 个盒子中各放一球的放法。第一个球有 n 种，第二个球有 $n - 1$ 种，……，第 n 个球有 1 种，这样，总可能数为 $n!$ ，因此，概率 $p_1 = \frac{n!}{N^n}$

(2) 因为恰好是有 n 个盒子中各有一球，所以我们可以分两步：第一步先从 N 个盒子中取出 n 个盒子，这样共有 C_N^n 种取法(组合数)；第二步将 n 个球放到 n 个盒子，每个盒子各一球，共有 $n!$ 种取法。因此，概率 $p_2 = \frac{C_N^n \cdot n!}{N^n} = \frac{N!}{N^n(N-n)!}$ 。


H5 3. 几何法

几何法的基本思想是：

- 如果一个随机现象的样本空间 Ω 能够充满某个区域，其度量(长度、面积或体积等)可用 S_Ω 表示
- 任意一点落在度量相同的子区域内(可能位置不同)是等可能的
- 若事件 A 为 Ω 种的某个子区域，其度量大小可用 S_A 表示，则事件 A 的概率是
$$P(A) = \frac{S_A}{S_\Omega}$$

我们举一个简单的例子：甲乙两人约定下午6时到7时之间在某处会面，并约定先到者应等候另一个人20min，过时即可离去，试求两人能会面的概率。

分析：以 x 和 y 分别表示甲乙两人到达约会地点的时间(以min为单位)，建立直角坐标系。因为两人均是在0至60min内等可能地到达，所以 (x, y) 的所有可能取值都在正方形区域内，其面积 $S_\Omega = 60^2$ 。而事件 A —“两人能够会面”，相当于两人到达的时间差不超过20分钟，即下图所示的阴影区域



其面积 $S_A = 60^2 - 40^2$ ，所以 $P(A) = \frac{S_A}{S_\Omega} = \frac{60^2 - 40^2}{60^2} = \frac{5}{9}$ 。

1.3. 条件概率

1.3.1. 条件概率公式


条件概率是概率论中重要且实用的概念，是指在某事件 B 发生的情况下，另一事件 A 发生的概率，记为 $P(A|B)$ 。前面我们说的事件 A 的(无条件)概率 $P(A)$ 是两个不同的概念。对于条件概率 $P(A|B)$ ，如果事件 B 的发生会影响到事件 A 发生的概率，那么 $P(A|B) \neq P(A)$ ；如果事件 B 的发生不会影响到事件 A 发生的概率，也就是我们常说的事件 A 与事件 B 相互独立，此时有 $P(A|B) = P(A)$ 。我们还是用一个简单的例子来说明：

有个家庭有两个小孩，其样本空间为 $\Omega = bb, bg, gb, gg$ 。其中 b 代表男孩， g 代表女孩， bg 代表大的是男孩， gb 代表大的是女孩。那么有

- 事件 A = “家中至少有一个女孩”发生的概率 $P(A) = \frac{3}{4}$
- 已知事件 B = “家中至少有一个男孩”，再求事件 A 发生的概率 $P(A|B) = \frac{2}{3}$

出现不同的原因是，在 B 发生的条件下，样本空间缩小为 $\Omega' = gg, bg, gb$ 。而在新样本空间中事件 A 的样本点只有两个，所以 $P(A|B) = \frac{2}{3}$ 。条件概率确切的定义如下：设 A 与 B 是样本空间 Ω 中的两事件，若 $P(B) > 0$ ，则称 $P(A|B) = \frac{P(AB)}{P(B)}$ 为“在 B 发生下 A 的概率”。

Ω



1.3.2. 乘法公式

乘法公式是条件概率的第一个重要应用，他从条件概率的角度描述了两个事件 A 、 B 同时发生的概率是怎么计算的，具体公式如下：

- 若 $P(B) > 0$ ，则 $P(AB) = P(B)P(A|B)$

○ 若 $P(A_1 A_2 \cdots A_{n-1}) > 0$, 则

$$P(A_1 A_2 \cdots A_n) = P(A_1)P(A_2 | A_1)P(A_3 | A_1 A_2) \cdots P(A_n | A_1 A_2 \cdots A_{n-1})$$

例子：一批零件共有 100 个，其中有 10 个不合格品。从中一个一个取出，求第三次才取得不合格品的概率是多少？

解析：以 A_i 记事件“第 i 次取出的是不合格品”， $i = 1, 2, 3$ 。则所求概率为 $P(\bar{A}_1 \bar{A}_2 A_3)$ ，由乘法公式得

$$P(\bar{A}_1 \bar{A}_2 A_3) = P(\bar{A}_1)P(\bar{A}_2 | \bar{A}_1)P(A_3 | \bar{A}_1 \bar{A}_2) = \frac{90}{100} \cdot \frac{89}{99} \cdot \frac{10}{98} = 0.0826.$$

1.3.3. 全概率公式

全概率公式是计算复杂概率的一个重要方法，使一个复杂概率的计算能化繁为简。设 B_1, B_2, \cdots, B_n 是基本空间 Ω 的一个分割，即 B_1, B_2, \cdots, B_n 互不相容，且 $\bigcup_{i=1}^n B_i = \Omega$ ，则对 Ω 中任一事件 A ，有 $P(A) = \sum_{i=1}^n P(A | B_i)P(B_i)$ 。

用一个简单的例子来说明一下，假设在 n 张彩票中有一张可中奖，求第二人摸到中奖彩票的概率。假设事件 A_i 表示事件“第 i 人摸到中奖彩票”， $i = 1, 2, \cdots, n$ 。现在要求 $P(A_2)$ ，因为 A_1 是否发生直接关系到 A_2 发生的概率，即 $P(A_2 | A_1) = 0$ ， $P(A_2 | \bar{A}_1) = \frac{1}{n-1}$ 。而 $P(A_1) = \frac{1}{n}$ ， $P(\bar{A}_1) = \frac{n-1}{n}$ 。根据全概率公式：

$$P(A_2) = P(A_1)P(A_2 | A_1) + P(\bar{A}_1)P(A_2 | \bar{A}_1) = \frac{1}{n} \cdot 0 + \frac{n-1}{n} \cdot \frac{1}{n-1} = \frac{1}{n}$$

这说明：摸到中奖彩票的机会与先后次序并无关联。

1.3.4. 贝叶斯公式

在乘法公式和全概率公式的基础上，可以得到贝叶斯公式。假设 B_1, B_2, \cdots, B_n 是样本空间 Ω 的一个分割，即 B_1, B_2, \cdots, B_n 互不相容，且 $\bigcup_{i=1}^n B_i = \Omega$ 。如果 $P(A) > 0$ ， $P(B_i) > 0$ ， $i = 1, 2, \cdots, n$ ，则：

$$P(B_i | A) = \frac{P(B_i)P(A | B_i)}{\sum_{j=1}^n P(B_j)P(A | B_j)}$$

这里我们简单推导一下，由条件概率公式 $P(B_i | A) = \frac{P(AB_i)}{P(A)}$ ，对分子分母分别用乘法公式、全概率公式，则有

$$P(AB_i) = P(B_i)P(A|B_i)$$

$$P(A) = \sum_{j=1}^n P(B_j)P(A|B_j)$$

因此，可以得到贝叶斯公式。

我们来看下面一个例子，某地区居民肝癌发病率为0.0004，现在进行普查(医学研究表明，化验结果是可能存在错误的)。已知患有肝癌的人其化验结果99%呈阳性(有病)，而没患肝癌的人其化验结果99.9%呈阴性(无病)。现某人检查结果呈阳性，试求其真的患病的概率。

解析：设事件 B ="检查者患有肝癌"，事件 A ="检查结果呈阳性"，由题可知：

$$P(B) = 0.0004, P(\bar{B}) = 0.9996$$

$$P(A|B) = 0.99, P(A|\bar{B}) = 1 - P(\bar{A}|\bar{B}) = 0.001$$

$$P(B|A) = \frac{P(B)P(A|B)}{P(B)P(A|B) + P(\bar{B})P(A|\bar{B})}$$

$$= \frac{0.0004 \times 0.99}{0.0004 \times 0.99 + 0.9996 \times 0.001} = 0.284$$

这说明，在检查结果呈阳性的人中，真正患肝癌的不到30%。所以在实际中，常采用复查的方法来减少错误率，譬如对首次检查呈阳性的人群进行复查，此时 $P(B) = 0.284$ ，这时我们再使用贝叶斯公式：

$$P(B|A) = \frac{0.284 \times 0.99}{0.284 \times 0.99 + 0.716 \times 0.001} = 0.997$$

这时检查的正确率大大提高。

需要注意的是：在贝叶斯公式中，如果称 $P(B_i)$ 为 B_i 的先验概率，那么 $P(B_i|A)$ 就是 B_i 的后验概率，贝叶斯公式就是专门计算后验概率的。也就是通过 A 的发生这个新信息，来对 B_i 的概率做出修正。我们再来举一个例子：狼来了的故事，我们知道前两次村民都是听了小孩子的谎话，但是第三次就不再相信，我们来做一个简单的模拟。

假设事件 B ="小孩可信"，事件 A ="小孩说谎"，我们要求得是 $P(B|A)$ ，也就是对于村民来说小孩说谎可信的概率。不妨设村民对小孩印象很好， $P(B) = 0.8, P(\bar{B}) = 0.2$ 。

在贝叶斯公式中，我们需要用到 $P(A|B)$ 和 $P(A|\bar{B})$ ，前者表示小孩可信的情况下说谎话的概率，后者表示小孩不可信的情况下说谎话的概率。不妨设 $P(A|B) = 0.1, P(A|\bar{B}) = 0.5$ ，这样第一次小孩说谎的时候，村民知道被骗之后，信任程度发生改变：

$$P(B|A) = \frac{P(B)P(A|B)}{P(B)P(A|B) + P(\bar{B})P(A|\bar{B})}$$

$$= \frac{0.8 \times 0.1}{0.8 \times 0.1 + 0.2 \times 0.5} = 0.444$$

在第一次被骗后，村民对小孩的信任度从0.8下降到0.444，在第二次知道被骗后

$$P(B|A) = \frac{P(B)P(A|B)}{P(B)P(A|B) + P(\bar{B})P(A|\bar{B})}$$

$$= \frac{0.444 \times 0.1}{0.444 \times 0.1 + 0.556 \times 0.5} = 0.138$$

信任度已经下降都0.138了，如此低的信任度，难怪第三次村民“不上当”了。

✧ 2. 随机变量及其分布

在前面我们提到过随机变量，我们把“用来表示随机现象结果的变量”称为随机变量，在这里，我们进一步来探讨关于随机变量的问题。

2.1. 随机变量及其分布

2.1.1. 随机变量的概念

在随机现象中很多样本点本身就是数量表示的(比如骰子点数)，但是也存在样本点本身不是数的情况。此时我们根据样本点的情况进行赋值(对于一个产品， X 表示样本合格情况， $X = 0$ 表示合格品， $X = 1$ 表示不合格品)，则 X 的取值及其对应概率如下表所示：

X	0	1
P	p	$1 - p$

定义在样本空间 Ω 上的实值函数 $X = X(\omega)$ 称为随机变量，常用大写字母 X, Y, Z 表示，其取值常用 x, y, z 表示。

2.1.2. 随机变量的分布函数

随机变量 X 是样本点 ω 的一个函数，若 B 是某些实数组成的集合，即 $B \subset \mathbf{R}$ ，则 $\{X \in B\}$ 表示如下的随机事件： $\{\omega : X(\omega) \in B\} \subset \Omega$ 。特别，用等号或者不等号把随机变量 X 与某些实数连接起来，用来表示事件，如 $\{X \leq a\}$ 、 $\{x > b\}$ 和 $\{a < X < b\}$ 都是随机事件。

设 X 是一个随机变量，对任意实数 x ，称 $F(x) = P(X \leq x)$ 为随机变量 X 的分布函数。任一分布函数 $F(x)$ 都具有如下三条基本性质：

- 单调性 $F(x)$ 是定义在整个实数轴 $(-\infty, +\infty)$ 上的单调非减函数，即对任意的 $x_1 < x_2$ ，有 $F(x_1) \leq F(x_2)$
- 有界性 对任意的 x ，有 $0 \leq F(x) \leq 1$ ，且

$$F(-\infty) = \lim_{x \rightarrow -\infty} F(x) = 0, F(+\infty) = \lim_{x \rightarrow +\infty} F(x) = 1。$$
- 右连续性 $F(x)$ 是 x 的右连续函数，即对任意的 x_0 ，有 $\lim_{x \rightarrow x_0+0} F(x) = F(x_0)$ 。

对任意的实数 a 与 b ，有

$$\begin{aligned} P(a < X \leq b) &= F(b) - F(a) \\ P(X = a) &= F(a) - F(a-0) \\ P(X \geq b) &= 1 - F(b-0) \\ P(X > b) &= 1 - F(b) \\ P(x < b) &= F(b-0) \\ P(a < X < b) &= F(b-0) - F(a) \\ P(a \leq X \leq b) &= F(b) - F(a-0) \\ P(a \leq X < b) &= F(b-0) - F(a-0) \end{aligned}$$

2.1.3. 离散随机变量的概率分布列

对于离散随机变量而言，常用以下定义的分布列来表示其分布

设 X 是一个离散随机变量，如果 X 的所有可能取值是 $x_1, x_2, \dots, x_n, \dots$ ，则称 X 取 x_i 的概率 $p_i = p(x_i) = P(X = x_i)$ 为 X 的概率分布列，记为 $X \sim p_i$ 。分布列也可以用如下表表示：

X	x_1	x_2	\cdots	x_n	\cdots
P	$p(x_1)$	$p(x_2)$	\cdots	$p(x_n)$	\cdots

分布列的基本性质：

- 非负性 $p(x_i) \geq 0, i = 1, 2, \dots$
- 正则性 $\sum_{i=1}^n p(x_i) = 1$

由分布列可以写出 X 的分布函数 $F(x) = \sum_{x_i \leq x} p(x_i)$

设离散随机变量 X 的分布列为

X	-1	2	3
P	0.25	0.5	0.25


试写出 X 的分布函数

$$F(x) = \begin{cases} 0, & x < -1 \\ 0.25, & -1 \leq x < 2 \\ 0.25 + 0.5 = 0.75, & 2 \leq x < 3 \\ 0.25 + 0.5 + 0.25 = 1, & x \geq 3 \end{cases}$$

2.1.4. 连续随机变量的概率密度函数

首先我们给个定义，设随机变量 X 的分布函数为 $F(x)$ ，如果存在实数轴上的一个非负可积函数 $p(x)$ ，使得对任意实数 x 有 $F(x) = \int_{-\infty}^x p(t)dt$ ，则称 $p(x)$ 为 X 的概率密度函数。下面我们再来看看是怎么推导的

加工机械的直径的测量值 X 是一个连续随机变量。若我们一个接一个地测量轴的直径，把测量值 x 一个接一个地放到数轴上去，当累积很多测量值 x 时，就形成一定的图形。为了使这个图形得以稳定，我们把纵轴由“单位长度上的频数”改为“单位长度上的频率”。由于频率的稳定性，随着测量值+的个数越多和单位越小，这个图形就越稳定，其外形就显现出一条光滑曲线(见下图)。这时，这条曲线的纵坐标已是“单位长度上的概率”，当单位长度趋于0时其纵坐标就是“一点上的概率密度”。这时，这条曲线所表示的函数 $p(x)$ 称为概率密度函数，它表示出 X “在一些地方(如中部)取值的机会大，在另一些地方(如两侧)取值机会小”的一种统计规律性。



概率密度函数 $p(x)$ 的值虽不是概率，但乘微分元 dx 就可得小区间 $(x, x+dx)$ 上概率的近似值，即 $p(x)dx \approx P(x < X < x+dx)$ 。在 (a, b) 上很多相邻的微分元的累加就得到 $p(x)$ 在 (a, b) 上的积分，也就是 X 在 (a, b) 上的概率，即

$\int_a^b p(x)dx = P(a < X < b)$ ，特别地，在 $(-\infty, x]$ 上 $p(x)$ 的积分就是分布函数 $F(x)$ ，即 $\int_{-\infty}^x p(t)dt = P(X \leq x) = F(x)$ 。同时，在 $F(x)$ 导数存在的点，有 $F'(x) = p(x)$ ，所以我们称 $p(x)$ 是概率密度函数。

2.1.5. 分布列与概率密度函数区别

- ① 离散随机变量的分布函数 $F(x)$ 总是右连续的阶梯函数，而连续随机变量的分布函数 $F(x)$ 是整个数轴上的连续函数
- ② 离散随机变量 X 在其可能取值的点上的概率不为0，而连续随机变量 X 在 $(-\infty, +\infty)$ 上任一点概率恒为0，这时因为 $P(X=a) = \int_a^a p(x)dx = 0$ 。这表明：不可能事件的概率为0，但概率为0的事件(如 $P(X=a)=0$)不一定是不可可能事件。类似地，必然事件的概率为1，但概率为1的事件不一定是必然事件。
- ③ 由于连续随机变量 X 在仅取一点处的概率恒为0，从而在事件 $\{a \leq X \leq b\}$ 中剔除端点并不影响其概率，即 $P(a \leq X \leq b) = P(a < X \leq b) = P(a \leq X < b) = P(a < X < b)$ 。
- ④ 从(3)可以看出，一个连续分布的密度函数不唯一，如下：

$$p_1(x) = \begin{cases} 1/a, & 0 \leq x \leq a \\ 0, & \text{其他} \end{cases}, p_2(x) = \begin{cases} 1/a, & 0 \leq x \leq a \\ 0, & \text{其他} \end{cases}$$

它们都是 $(0, a)$ 上均匀分布的密度函数，但仔细考察这两个函数 $p_1(x)$ 和 $p_2(x)$ ，可以发现

$P(p_1(x) \neq p_2(x)) = P(X=0) + P(X=a) = 0$ ，可见这两个函数在概率意义上是没有差别的，这是概率论与微积分不同之处。

2.2. 随机变量的数学期望

对于一个离散随机变量 X ，如果其可能取值为 x_1, x_2, \dots, x_n 。若将这 n 个数相加后除 n 作为“均值”，则肯定是不妥的。其原因在于 X 取各个值的概率一般是不同的，概率大的出现的机会就大，则在计算中其权也应该大，因此用取值的概率作为一种“权数”作加权平均是十分合理的。经以上分析,我们就可以给出数学期望的定义：

设离散随机变量 X 的分布列为 $p(x_i) = P(X = x_i), i = 1, 2, \dots, n, \dots$, 如果 $\sum_{i=1}^n |x_i| p(x_i) < \infty$, 则称 $E(x) = \sum_{i=1}^n x_i p(x_i)$ 为随机变量 X 的数学期望, 简称期望或均值。从定义我们可以看到, 如果级数 $\sum_{i=1}^n |x_i| p(x_i)$ 不收敛, 那么 X 的数学期望不存在。

同样的, 我们可以得出连续随机变量的期望: 设连续随机变量 X 的概率密度函数为 $p(x)$, 如果 $\int_{-\infty}^{+\infty} |x| f(x) dx < \infty$, 则称 $E(X) = \int_{-\infty}^{+\infty} x f(x) dx$ 为 X 的数学期望。同样的, 如果 $\int_{-\infty}^{+\infty} |x| f(x) dx$ 不收敛, 那么 X 的数学期望不存在。

我们分别举例来说明~

在一个人数为 N 的人群中普查某种疾病, 为此要抽验 N 个人的血。如果将每个人的血分别检验, 则共需检验 N 次。为了能减少工作量, 一位统计学家提出一种方法: 按 k 个人一组进行分组, 把同组 k 个人的血样混合后检验, 如果混合血样呈阴性反应, 就说明这 k 个人的血都呈阴性反应, 这 k 个人都无此疾病, 因而这 k 个人只要检验1次就够了, 相当于每个人检验 $1/k$ 次, 检验的工作量明显减少了。如果混合血样呈阳性反应, 就说明这 k 个人中至少有一人的血呈阳性反应, 则再对这 k 个人的血样分别进行检验, 因而这 k 个人的血要检验 $k + 1$ 次, 相当于每个人检验 $1 + 1/k$ 次, 这时增加了检验次数。假设该疾病的发病率为 p , 且得此疾病相互独立。试问此种方法能否减少平均检验次数?

分析: 设 X 为每个人需要检验的次数, 则 X 的分布列为

$$\begin{array}{c|cc} X & 1/k & 1 + 1/k \\ \hline P & (1-p)^k & 1 - (1-p)^k \end{array}$$

则每个人的平均检测次数

$$E(x) = \frac{1}{k}(1-p)^k + \left(1 + \frac{1}{k}\right)[1 - (1-p)^k] = 1 - (1-p)^k + \frac{1}{k}。$$

只要使 $(1-p)^k > \frac{1}{k}$, 就可减少验血次数, 而且还可适当选择 k 使 $E(X)$ 达到最小。譬如, 当 $p = 0.1$ 时, 对不同的 k , 当 $k \geq 34$ 时, 平均验血次数超过1, 即比分别检验的工作量还大; 而当 $k \leq 33$ 时, 平均验血次数在不同程度上得到了减少, 特别在 $k = 4$ 时, 平均验血次数最少, 验血工作量可减少 40%。

设 X 是服从区间 (a, b) 上的均匀分布, 求 $E(x)$ 。均匀分布的概率密度函数为

$$p_1(x) = \begin{cases} \frac{1}{b-a}, & a \leq x < b \\ 0, & \text{其他} \end{cases}$$

所以

$$E(X) = \int_a^b \frac{x}{b-a} dx = \frac{1}{b-a} \cdot \frac{x^2}{2} \Big|_a^b = \frac{a+b}{2}$$

实际上，因为 X 在区间 (a, b) 上是均匀分布的，所以均值当然就是区间 (a, b) 的中点，即 $(a+b)/2$ 。

再来简单说说数学期望的性质：

- 若 c 是常数，则 $E(c) = c$ 。
- 对任意常数 a ，有 $E(aX) = aE(X)$ 。
- 设 (X, Y) 是二维随机变量，则有 $E(X+Y) = E(X) + E(Y)$ 。
- 若随机变量 X 与 Y 相互独立，则有 $E(XY) = E(X)E(Y)$ 。

2.3. 随机变量的方差和标准差

前面我们说到期望可以衡量随机变量 X 的均值，也就是 X 总是在 $E(X)$ 附近波动，那如何才能反映随机变量取值的波动大小呢，比如对于下面两个分布：

X	-1	0	1
P	1/3	1/3	1/3

Y	-10	0	10
P	1/3	1/3	1/3

虽然两个分布的均值都为0，但是很明显 Y 的取值波动更大，所以我们引入方差和标准差来度量波动大小。

若随机变量 X^2 的数学期望 $E(X^2)$ 存在，则称偏差平方 $(X - E(X))^2$ 的数学期望 $E(X - E(X))^2$ 为随机变量 X 的方差，记为

$$Var(X) = E(X - E(X))^2 = \begin{cases} \sum_i (x_i - E(X))^2 p(x_i), & X \text{ 为离散随机变量} \\ \int_{-\infty}^{\infty} (x - E(X))^2 p(x) dx, & X \text{ 为连续随机变量} \end{cases}$$

而方差的正平方根，则被称为标准差，记为 $\sigma(X)$ 。

方差与标准差的功能相似，它们都是用来描述随机变量取值的集中与分散程度(即散布大小)的两个特征数。方差与标准差愈小，随机变量的取值愈集中；方差与标准差愈大，随机变量的取值愈分散。

方差与标准差之间的差别主要在量纲上，由于标准差与所讨论的随机变量、数学期望有相同的量纲，其加减 $E(X) \pm k\sigma(X)$ 是有意义的(k 为正实数)，所以在实际中，人们比较乐意选用标准差，但标准差的计算必须通过方差才能算得。

另外要指出的是：如果随机变量 X 的数学期望存在，其方差不一定存在；而当 X 的方差存在时，则 $E(X)$ 必定存在，其原因在于 $|x| \leq x^2 + 1$ 总是成立的。

关于方差的计算，我们这里不再举例，主要是要了解方差的性质：

- 最重要的性质： $Var(X) = E(X^2) - [E(X)]^2$ 。
- 常数的方差为0，即 $Var(c) = 0$ ，其中 c 是常数。
- 若 a, b 是常数，则 $Var(aX + b) = a^2 Var(X)$ 。
- 若随机变量 X 与 Y 相互独立，则有 $Var(X \pm Y) = Var(X) + Var(Y)$ 。

2.4. 常见离散分布

接下来我们来了解以下常见的离散分布，以及对应的数学期望和方差

2.4.1. 二项分布

首先我们了解一个概念，伯努利试验。伯努利试验是在同样的条件下重复地、相互独立地进行的一种随机试验，其特点是该随机试验只有两种可能结果：发生或者不发生。我们假设该项试验独立重复地进行了 n 次，那么就称这一系列重复独立的随机试验为 n 重伯努利试验。

如果记 X 为 n 重伯努利试验中成功(记为事件 A)的次数，则 X 的可能取值为 $0, 1, \dots, n$ 。记 p 为每次试验 A 发生的概率，则有 $p(A) = p, p(\bar{A}) = 1 - p$ 。下面我们求 X 的分布列，即求事件 $\{X = k\}$ 的概率，这意味着成功了 k 次，失败了 $n - k$ 次，从组合可以得到， $P(X = k) = C_n^k p^k (1 - p)^{n-k}, k = 0, 1, \dots, n$ 。这个分布就被称为二项分布，记为 $X \sim b(n, p)$ 。

下面我们来求一下二项分布的期望和方差：

$$\begin{aligned} E(X) &= \sum_{k=0}^n k C_n^k p^k (1-p)^{n-k} \\ &= \sum_{k=1}^n n p C_{n-1}^{k-1} p^{k-1} (1-p)^{(n-1)-(k-1)} \\ &= n p \sum_{k=1}^n C_{n-1}^{k-1} p^{k-1} (1-p)^{(n-1)-(k-1)} \\ &= n p [p + (1-p)]^{n-1} = n p \\ \text{其中, } C_n^k &= \frac{n!}{(n-k)!k!} = \frac{n \cdot (n-1)!}{((n-1)-(k-1))!(k \cdot (k-1)!) } \\ &= \frac{n}{k} C_{n-1}^{k-1} \end{aligned}$$

而

$$\begin{aligned}
E(X^2) &= \sum_{k=0}^n k^2 C_n^k p^k (1-p)^{n-k} = \sum_{k=0}^n (k-1+1)k C_n^k p^k (1-p)^{n-k} \\
&= \sum_{k=0}^n k(k-1) C_n^k p^k (1-p)^{n-k} + \sum_{k=0}^n k C_n^k p^k (1-p)^{n-k} \\
&= \sum_{k=0}^n k(k-1) C_n^k p^k (1-p)^{n-k} + np \\
&= \sum_{k=0}^n k(k-1) C_n^k p^k (1-p)^{n-k} + np \\
&= n \cdot (n-1) \sum_{k=2}^n p^2 C_{n-2}^{k-2} p^{k-2} (1-p)^{(n-2)-(k-2)} + np \\
&= n(n-1)p^2 + np \\
\text{其中, } C_n^k &= \frac{n!}{(n-k)!k!} = \frac{n \cdot (n-1) \cdot (n-2)!}{((n-2)-(k-2))!(k \cdot (k-1) \cdot (k-2)!)} \\
&= \frac{n \cdot (n-1)}{k \cdot (k-1)} C_{n-2}^{k-2}
\end{aligned}$$

因此, $Var(X) = E(X^2) - [E(X)]^2 = n(n-1)p^2 + np - n^2p^2 = np(1-p)$


当 $n=1$ 时, 我们可以看到此时二项分布为 $b(1, p)$, 此时就是 0-1 分布。

我们通过图像来简单看一下二项分布

```

1  # 使用scipy的pmf和cdf画图
2  from scipy.stats import binom
3
4  n=10
5  x=np.arange(1,n+1,1)
6
7  fig, axes = plt.subplots(1, 3, figsize=(15, 4))
8  for i, (p, line_type) in enumerate(zip([0.2, 0.5, 0.8], ['右偏',
9  '对称', '左偏'])):
10     pList=binom.pmf(x,n,p)
11     axes[i].plot(x,pList,marker='o',alpha=0.7,linestyle='None')
12     axes[i].vlines(x, 0, pList)
13     axes[i].set_xlabel(f'b({n}, {p})的线条图({line_type})')
14     axes[i].set_ylabel('概率')
15     axes[i].set_title(f'二项分布: n={n}, p={p:.2f}')
16 plt.show()

```



2.4.2. 泊松分布

泊松分布的概率分布列是 $P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}$, $k = 0, 1, 2, \dots$, 其中参数 $\lambda > 0$, 记为 $X \sim P(\lambda)$ 。泊松分布是一种常用的离散分布, 它常与单位时间 (或单位面积、单位产品等) 上的计数过程相联系, 譬如,

- 在一天内, 来到某商场的顾客数。(λ 就是单位时间内商场的顾客数)
- 在单位时间内, 一电路受到外界电磁波的冲击次数。
- 1平方米内, 玻璃上的气泡数。
- 一铸件上的砂眼数。
- 在一定时期内, 某种放射性物质放射出来的 α -粒子数, 等等。

下面我们来看以下泊松分布的期望和方差。

$$\begin{aligned} E(X) &= \sum_{k=0}^{\infty} k \frac{\lambda^k}{k!} e^{-\lambda} = \lambda e^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} \\ &= \lambda e^{-\lambda} e^{\lambda} = \lambda \end{aligned}$$

$$\text{其中, } e(\lambda) = 1 + x + \frac{x^2}{2!} + \dots + \frac{x^n}{n!} + \dots$$

$$= \sum_{k=0}^{\infty} \frac{x^k}{k!} = \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!}$$

$$E(X^2) = \sum_{k=0}^{\infty} k^2 \frac{\lambda^k}{k!} e^{-\lambda} = \sum_{k=1}^{\infty} k \frac{\lambda^k}{(k-1)!} e^{-\lambda}$$

$$= \sum_{k=1}^{\infty} (k-1+1) \frac{\lambda^k}{(k-1)!} e^{-\lambda}$$

$$= \sum_{k=1}^{\infty} (k-1) \frac{\lambda^k}{(k-1)!} e^{-\lambda} + \lambda$$


$$= \lambda^2 \sum_{k=1}^{\infty} (k-2) \frac{\lambda^{k-2}}{(k-2)!} e^{-\lambda} + \lambda$$

$$= \lambda^2 + \lambda$$

$$Var(X) = E(X^2) - [E(X)]^2 = \lambda^2 + \lambda - \lambda^2 = \lambda$$

我们再来看一下泊松分布的图像

```
1 import math
2
3 def poisson(lamb, k):
4     return math.exp(-lamb) * lamb ** k / math.factorial(k)
5
6 x = [i for i in range(10)]
7 lambs = [0.8, 2.0, 4.0]
8 ps = [[poisson(lamb, i) for i in range(10)] for lamb in lambs]
9
10 fig, axes = plt.subplots(1, 3, figsize=(15, 4))
11 for i, (lamb, p) in enumerate(zip(lambs, ps)):
12     axes[i].plot(x, p, marker='o', alpha=0.7, linestyle='None')
13     axes[i].vlines(x, 0, p)
14     axes[i].set_xlabel(f'P({lamb})的线条图')
15     axes[i].set_ylabel('概率')
16     axes[i].set_title(f'$\lambda={lamb}$')
```



2.5. 常见连续分布

2.5.1. 正态分布

若随机变量 X 的密度函数为 $p(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$, $-\infty < x < +\infty$, 则称 X 服


从正态分布, 记作 $X \sim N(\mu, \sigma^2)$ 。我们来看一下正态分布的图像:

```
1 def normal(mu, sigma):
2     return np.exp(-0.5 * (x- mu) ** 2 / (sigma ** 2)) /
3     (math.sqrt(2 * math.pi) * sigma)
4
5 x = np.linspace(-3, 3, 40)
6 params = [(0.5, 1), (0, 1), (0, 0.5)]
7 colors = ["green", "red", "blue"]
```

```

7
8 plt.figure(figsize=(12, 8))
9 for i, (param, color) in enumerate(zip(params, colors)):
10     mu, sigma = param
11     y = normal(mu, sigma)
12     plt.plot(x, y, color=color, linewidth=2, label=f"$\mu={mu}$,
13             \sigma={sigma}$")
14     plt.vlines(mu, 0, 5, linestyle='--')
15 plt.text(-0.5, 1.2, "$\mu=0$")
16 plt.text(0.7, 1.2, "$\mu=0.5$")
17 plt.legend(loc="center left")
18 plt.show()

```



从图中可以看出：如果固定 σ ，改变 μ 的值，则图形沿 x 轴平移，而不改变其形状。也就是说正态密度函数的位置由参数 μ 所确定，因此亦称 μ 为位置参数；同时如果固定 μ ，改变 σ 的值，则分布的位置不变，但 σ 愈小，曲线呈高而瘦，分布较为集中； σ 愈大，曲线呈矮而胖，分布较为分散。也就是说正态密度函数的尺度由参数 σ 所确定，因此称 σ 为尺度参数。

我们将 $\mu = 0, \sigma = 1$ 的正态分布称为标准正态分布。对于标准正态分布，有

- $\Phi(-u) = 1 - \Phi(u)$
- $P(U > u) = 1 - \Phi(u)$
- $P(a < U < b) = \Phi(b) - \Phi(a)$
- $P(|U| < c) = 2\Phi(c) - 1 (c \geq 0)$

我们再来看一下正态分布的数学期望和方差，由于 $U = (X - \mu)/\sigma \sim N(0, 1)$

$$E(U) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} u e^{-\frac{u^2}{2}} du$$

因为被积函数是奇函数，所以 $E(U) = 0$, $E(X) = E(\mu + \sigma U) = \mu$

$$\begin{aligned} Var(U) &= E(U^2) - [E(U)]^2 = E(U^2) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} u^2 e^{-\frac{u^2}{2}} du \\ &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} u d(-e^{-\frac{u^2}{2}}) = \frac{1}{\sqrt{2\pi}} \left(-ue^{-\frac{u^2}{2}} + \int_{-\infty}^{\infty} e^{-\frac{u^2}{2}} du \right) \\ &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{u^2}{2}} du \\ &= \frac{1}{\sqrt{2\pi}} \cdot \sqrt{2\pi} = 1 \end{aligned}$$

$$\begin{aligned} \text{其中, } \int_{-\infty}^{\infty} e^{-\frac{u^2}{2}} du &= \sqrt{\int_{-\infty}^{\infty} e^{-\frac{x^2}{2}} dx \int_{-\infty}^{\infty} e^{-\frac{y^2}{2}} dy} \\ &= \sqrt{\iint e^{-\frac{x^2+y^2}{2}} dx dy} = \sqrt{\int_0^{2\pi} d\theta \int_0^{+\infty} r e^{-\frac{r^2}{2}} dr} \\ &= \sqrt{2\pi \cdot (-e^{-\frac{r^2}{2}})|_0^{+\infty}} = \sqrt{2\pi} \end{aligned}$$

所以 $Var(X) = Var(\mu + \sigma U) = \sigma^2 \cdot Var(U) = \sigma^2$ 。在正态分布中，有一个 3σ 原则需要注意：

$$P(\mu - k\sigma < X < \mu + k\sigma) = P\left(\left|\frac{X - \mu}{\sigma}\right| < k\right) = 2\Phi(k) - 1$$

$$P(\mu - \sigma < X < \mu + \sigma) = 2\Phi(1) - 1 = 0.6826$$

$$P(\mu - 2\sigma < X < \mu + 2\sigma) = 2\Phi(2) - 1 = 0.9545$$

$$P(\mu - 3\sigma < X < \mu + 3\sigma) = 2\Phi(3) - 1 = 0.9973$$

2.5.2. 均匀分布

其实我们前面在讲期望的时候就已经说过均匀分布了，其概率密度函数为：

$$p(x) = \begin{cases} \frac{1}{b-a}, & a \leq x < b \\ 0, & \text{其他} \end{cases}$$

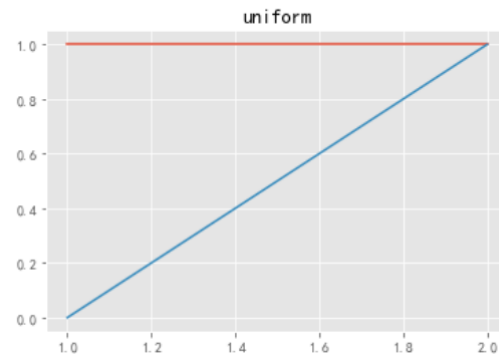
其图像如下图所示：

```

a, b = 1.0, 2.0
x = np.linspace(a, b)
y = np.full_like(x, fill_value=1 / (b - a))

plt.plot(x, y)
plt.plot(x, (x - a) / (b - a))
plt.title("uniform");

```



$$E(X) = \int_a^b \frac{x}{b-a} dx = \frac{x^2}{2(b-a)} \Big|_a^b = \frac{a+b}{2}$$

$$E(X^2) = \int_a^b \frac{x^2}{b-a} dx = \frac{x^3}{3(b-a)} \Big|_a^b = \frac{a^2 + ab + b^2}{3}$$

$$Var(X) = E(X^2) - [E(X)]^2 = \frac{(b-a)^2}{12}$$


2.5.3. 指数分布

若随机变量 X 的密度函数为

$$p(x) = \begin{cases} \lambda e^{-\lambda}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

$$F(x) = \begin{cases} 1 - e^{-\lambda}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

指数分布是一种偏态分布，由于指数分布随机变量只可能取非负实数,所以指数分布常被用作各种“寿命”分布,譬如电子元器件的寿命、动物的寿命、电话的通话时间、随机服务系统中的等待时间等都可假定服从指数分布.指数分布在可靠性与排队论中有着广泛的应用。我们来看一下其分布：



最后再来看一下指数分布的期望和方差：

$$\begin{aligned}
 E(X) &= \int_0^{+\infty} x \lambda e^{-\lambda x} dx = \int_0^{+\infty} x d(-e^{-\lambda x}) \\
 &= -x e^{-\lambda x} \Big|_0^{+\infty} + \int_0^{+\infty} e^{-\lambda x} dx \\
 &= -\frac{1}{\lambda} \cdot e^{-\lambda x} \Big|_0^{+\infty} = \frac{1}{\lambda} \\
 E(X^2) &= \int_0^{+\infty} x^2 \lambda e^{-\lambda x} dx = \int_0^{+\infty} x^2 d(-e^{-\lambda x}) \\
 &= -x^2 e^{-\lambda x} \Big|_0^{+\infty} + 2 \int_0^{+\infty} x e^{-\lambda x} dx \\
 &= \frac{2}{\lambda} E(X) = \frac{2}{\lambda^2} \\
 Var(X) &= E(X^2) - [E(X)]^2 = \frac{1}{\lambda^2}
 \end{aligned}$$

指数分布有一项特殊的性质——无记忆性。如果随机变量 $X \sim Exp(\lambda)$ ，那么对于任意 $s > 0, t > 0$ ，有 $P(X > s + t | X > s) = P(X > t)$ ，证明如下：

$$\begin{aligned}
 \{X > s + t\} &\subset \{X > s\} \\
 P(X > s + t | X > s) &= \frac{P(X > s + t)}{P(X > s)} = \frac{1 - (1 - e^{-(s+t)})}{1 - (1 - e^{-s})} = e^{-t} = P(X > t)
 \end{aligned}$$

2.7. 分布的其他特征数

除了数学期望和方差外，随机变量还有一些很重要的特征数，下面我们逐一给出定义和解释。

2.7.1. k阶矩

设 X 为随机变量， k 为正整数，如果 $\mu_k = E(X^k)$ 都存在，则称 μ_k 为 X 的 k 阶原点矩；如果 $v_k = E(X - E(X))^k$ 为 X 的 k 阶中心矩。我们举个简单例子：

设随机变量 $X \sim N(0, \sigma^2)$ ，则

$$\begin{aligned}
 \mu_k = E(X^k) &= \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^{\infty} x^k \exp\left\{-\frac{x^2}{2\sigma^2}\right\} dx \\
 &= \frac{\sigma^k}{\sqrt{2\pi}} \int_{-\infty}^{\infty} u^k \exp\left\{-\frac{u^2}{2}\right\} du
 \end{aligned}$$

其中, $u = \frac{x}{\sigma}$ 。

当 k 为奇数时，上述被积函数是基函数，故 $\mu_k = 0, k = 1, 3, 5, \dots$ 。当 k 为偶数时，上述被积函数是偶函数，再利用变换 $z = u^2/2$ ，可得

$$\begin{aligned}
u_k &= \sqrt{\frac{2}{\pi}} \sigma^k 2^{\frac{k-1}{2}} \int_0^\infty z^{(k-1)/2} e^{-z} dz \\
&= \sqrt{\frac{2}{\pi}} \sigma^k 2^{(k-1)/2} \Gamma\left(\frac{k+1}{2}\right) \\
&= \sigma^k (k-1)(k-3) \cdots 1 \quad k = 2, 4, 6, \dots
\end{aligned}$$

故 $N(0, \sigma^2)$ 分布的前四阶原点矩为 $\mu_1 = 0$, $\mu_2 = \sigma^2$, $\mu_3 = 0$, $\mu_4 = 3\sigma^4$, 又因为 $E(X) = 0$, 所以原点矩等于中心矩。

2.7.2. 变异系数

方差(或标准差)反映了随机变量取值的波动程度, 但在比较两个随机变量的波动大小时, 如果仅看方差(或标准差)的大小有时会产生不合理的现象。这有两个原因:
(1)随机变量的取值有量纲, 不同量纲的随机变量用其方差(或标准差)去比较它们的波动大小不太合理(2)在取值的量纲相同的情况下, 取值的大小有一个相对性问题, 取值较大的随机变量的方差(或标准差)也允许大一些。所以要比较两个随机变量的波动大小时, 在有些场合使用以下定义的变异系数来进行比较, 更具可比性。

设随机变量 X 的二阶矩存在, 则称比值 $C_v(X) = \frac{\sqrt{\text{Var}(X)}}{E(X)} = \frac{\sigma(X)}{E(X)}$ 为 X 的变异系数。变异系数是一个无量纲的量, 从而可以消除量纲对波动的影响。

2.7.3. 分位数


设连续随机变量 X 的分布函数为 $F(x)$, 密度函数为 $p(x)$, 对任意的 $p \in (0, 1)$, 称满足条件

$$F(x_p) = \int_{-\infty}^{x_p} p(x) dx = p$$

的 x_p 为此分布的 p 分位数, 又称下侧 p 分位数。分位数 x_p 把密度函数下的面积分为两块, 左侧面积恰好为 p 。同理我们称满足条件

$$1 - F(x'_p) = \int_{x'_p}^{\infty} p(x) dx = p$$

的 x'_p 为此分布的上侧 p 分位数。




分位数与上侧分位数是可以相互转换的，其转换公式如下：

$$x'_p = x_{1-p}, \quad x_p = x'_{1-p}$$

2.7.4. 中位数

设连续随机变量 X 的分布函数为 $F(x)$ ，密度函数为 $p(x)$ ，称 $p = 0.5$ 时的 p 分位数 $x_{0.5}$ 为此分布的中位数，即

$$F(x_p) = \int_{-\infty}^{x_{0.5}} p(x) dx = 0.5$$



中位数与均值一样都是随机变量位置的特征数，但在某些情况可能中位数比均值更能说明问题。比如在统计某个行业工资水平，直接使用平均数可能会导致大部分人被平均，这种情况用中位数就更能反映工资水平。


我们使用 `python` 来计算分位数水平。

```
from scipy.stats import norm
print("标准正态分布的0.25分位数: ", norm(loc=0, scale=1).ppf(0.25)) # 使用ppf计算分位数点
print("标准正态分布的0.5分位数: ", norm(loc=0, scale=1).ppf(0.5))
print("标准正态分布的0.75分位数: ", norm(loc=0, scale=1).ppf(0.75))
print("标准正态分布的0.95分位数: ", norm(loc=0, scale=1).ppf(0.95))
```

```
标准正态分布的0.25分位数:  -0.6744897501960817
标准正态分布的0.5分位数:   0.0
标准正态分布的0.75分位数:   0.6744897501960817
标准正态分布的0.95分位数:   1.6448536269514722
```

2.7.5. 偏度系数

设随机变量 X 的前三阶矩存在，则比值 $\beta_s = \frac{v_3}{v_2^{3/2}} = \frac{E(X - E(X))^3}{[Var(X)]^{3/2}}$ 称为 X 的偏度系数，简称偏度。当 $\beta_s > 0$ ，则该分布为右偏；当 $\beta_s < 0$ ，则该分布为左偏。偏度是描述分布偏离对称性程度的一个特征数，分布的三阶中心矩决定偏度的符号，而分布的标准差 $\sigma(X)$ 决定偏度大小。



2.7.6. 峰度系数

设随机变量 X 的前四阶矩存在，则比值 $\beta_k = \frac{v_4}{v_2^2} - 3 = \frac{E(X - E(X))^4}{[Var(X)]^2} - 3$ 称为 X 的峰度系数，简称峰度。峰度是描述分布尖峭程度和尾部粗细的一个特征数。

✧ 3. 多维随机变量及其分布

在某些随机现象中，对每个样本点 ω 只用一个随机变量去描述是不够的，这时可能需要两个以上随机变量，我们先来研究联合分布函数，再研究离散随机变量的联合分布列、连续随机变量的联合密度函数等。

3.1. 多维随机变量及其联合分布

对于任意的 n 个实数 x_1, x_2, \dots, x_n ， n 个事件 $\{X_1 \leq x_1\}, \{X_2 \leq x_2\}, \dots, \{X_n \leq x_n\}$ 同时发生的概率 $F(x_1, x_2, \dots, x_n) = P(X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n)$ 称为 n 维随机变量 (X_1, X_2, \dots, X_n) 的联合分布函数。

3.1.1. 联合分布列

如果二维随机变量 (X, Y) 只取有限个数对 (x_i, y_i) ，则称 (X, Y) 为二维离散随机变量，称 $P_{ij} = P(X = x_i, Y = y_j)$ ， $i, j = 1, 2, \dots$ 为 (X, Y) 的联合分布列，也可以用如下表格表示联合分布列：

X	Y				
	y_1	y_2	\dots	y_j	\dots
x_1	p_{11}	p_{12}	\dots	p_{1j}	\dots
x_2	p_{21}	p_{22}	\dots	p_{2j}	\dots
\vdots	\vdots	\vdots		\vdots	
x_i	p_{i1}	p_{i2}	\dots	p_{ij}	\dots
\vdots	\vdots	\vdots		\vdots	

求二维离散随机变量的联合分布列，关键是要写出二维随机变量可能取得数对及其发生得概率，我们举一个简单例子来说明。

从 $1, 2, 3, 4$ 中任取一数记为 X ，再从 $1, 2, \dots, X$ 中任取一数记为 Y 。求 (X, Y) 的联合分布列及 $P(X = Y)$ 。

分析： (X, Y) 为二维离散随机变量，其中 X 的分布列为 $P(X = i) = 1/4$ ， $i = 1, 2, 3, 4$ 。 Y 的可能取值也是 $1, 2, 3, 4$ ，若记 j 为 Y 的取值，则当 $j > i$ 时，有 $P(X = i, Y = j) = 0$ ，当 $1 \leq j \leq i \leq 4$ 时，由乘法公式： $P(X = i, Y = j) = P(X = i)P(Y = j|X = i) = \frac{1}{4} \times \frac{1}{i}$ 。

因此 (X, Y) 的联合分布列为

X	Y			
	1	2	3	4
1	1/4	0	0	0
2	1/8	1/8	0	0
3	1/12	1/12	1/12	0
4	1/16	1/16	1/16	1/16

因此， $P(X = Y) = p_{11} + p_{22} + p_{33} + p_{44} = \frac{1}{4} + \frac{1}{8} + \frac{1}{12} + \frac{1}{16} = \frac{25}{48}$ 。

3.1.2. 联合密度函数

如果存在二元非负函数 $p(x, y)$ ，使得二维随机变量 (X, Y) 的分布函数 $F(x, y)$ 可表示为：

$$F(x, y) = \int_{-\infty}^x \int_{-\infty}^y p(u, v) du dv$$

则称 (X, Y) 为二维连续随机变量， $p(x, y)$ 为 (X, Y) 的联合密度函数。在 $F(x, y)$ 偏导数存在的点上有 $p(x, y) = \frac{\partial^2}{\partial x \partial y} F(x, y)$ 。

同样的，我们举一个简单的例子。设 (X, Y) 的联合密度函数为

$$p(x, y) = \begin{cases} 6e^{-2x-3y}, & x > 0, y > 0 \\ 0, & \text{其他} \end{cases}$$

试求(1) $P(X < 1, Y > 1)$; (2) $P(X > Y)$


解析：（1）对应积分区域如下所示：

$$\begin{aligned} P(X < 1, Y > 1) &= P((X, Y) \in D_1) = \int_0^1 \int_1^{+\infty} 6e^{-2x-3y} dx dy \\ &= (1 - e^{-2})e^{-3} \end{aligned}$$



(2)对应积分区域如下所示：

$$\begin{aligned} P(X > Y) &= P((X, Y) \in D_2) = \int_0^{\infty} \int_0^x 6e^{-2x-3y} dx dy \\ &= \left(-e^{-2x} + \frac{2}{5}e^{-5x} \right) \Big|_0^{+\infty} = \frac{3}{5} \end{aligned}$$



3.2. 边际分布与随机变量的独立性

二维联合分布函数含有丰富的信息，主要包括：

- 每个分量的分布(每个分量的所有信息)，即边际分布
- 两个分量之间的关联程度，可用协方差和相关系数来描述
- 给定一个分量时，求另一个分量的分布，即条件分布

3.2.1. 边际分布函数

如果在二维随机变量 (X, Y) 的联合分布函数 $F(x, y)$ 中令 $y \rightarrow \infty$ ，由于 $\{Y < \infty\}$ 为必然事件，故可得

$$\lim_{y \rightarrow \infty} F(x, y) = P(X \leq x, Y < \infty) = P(X \leq x)$$

这是由 (X, Y) 的联合分布函数 $F(x, y)$ 求得的 X 的分布函数，被称为 X 的边际分布，记为 $F_X(x) = F(x, \infty)$ 。类似地，在 $F(x, y)$ 中令 $x \rightarrow \infty$ ，可得 Y 的边际分布 $F_Y(y) = F(\infty, y)$ 。我们这里举一个简单例子：

设二维随机变量 (X, Y) 的联合分布函数为

$$F(x, y) = \begin{cases} 1 - e^{-x} - e^{-y} + e^{-x-y-\lambda xy}, & x > 0, y > 0. \\ 0, & \text{其他} \end{cases}$$

这个分布被称为二维指数分布，其中参数 $\lambda > 0$ 。

由此联合分布函数 $F(x, y)$ ，容易获得 X 与 Y 的边际分布函数为

$$F_X(x) = F(x, \infty) = \begin{cases} 1 - e^{-x}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$
$$F_Y(y) = F(\infty, y) = \begin{cases} 1 - e^{-y}, & y > 0 \\ 0, & y \leq 0 \end{cases}$$

不同的 λ 对应不同的二维指数分布，但是它们的边际分布与 λ 无关。这说明二维联合分布不仅含有每个分量的概率分布，而且还含有两个变量 X 与 Y 间关系的信息。

3.2.2. 边际分布列

在二维离散随机变量 (X, Y) 的联合分布列 $\{P(X = x, Y = y)\}$ 中，对 j 求和所得的分布列

$$\sum_{j=1}^{\infty} P(X = x, Y = y_j) = P(X = x_i), \quad i = 1, 2, \dots$$

被称为 X 的分布列。类似的，对 i 求和所得的分布列

$$\sum_{i=1}^{\infty} P(X = x_i, Y = y_j) = P(Y = y_j), \quad j = 1, 2, \dots$$

被称为 Y 的分布列。

我们举个简单的例子。设二维随机变量 (X, Y) 有如下的联合分布列

X	Y		
	1	2	3
0	0.09	0.21	0.24
1	0.07	0.12	0.27

求 X 与 Y 的分布列。

解析：对上面联合分布中，每行求和得0.54和0.46，这就是 X 对应的概率；再对每一列求和，分别得到0.16, 0.33, 0.51，这就是 Y 对应的概率。我们将其写在联合分布列，则有：

X	Y			$P(X=i)$
	1	2	3	
0	0.09	0.21	0.24	0.54
1	0.07	0.12	0.27	0.46
$P(Y=j)$	0.16	0.33	0.51	1

3.2.3. 边际密度函数

如果二维连续随机变量 (X, Y) 的联合概率密度函数为 $p(x, y)$ ，因为

$$F_X(x) = F(x, \infty) = \int_{-\infty}^x \left(\int_{-\infty}^{\infty} p(u, v) dv \right) du = \int_{-\infty}^x p_X(u) du$$

$$F_Y(y) = F(\infty, y) = \int_{-\infty}^y \left(\int_{-\infty}^{\infty} p(u, v) du \right) dv = \int_{-\infty}^y p_Y(v) dv$$

其中，

$$p_X(x) = \int_{-\infty}^{\infty} p(x, y) dy$$

$$p_Y(y) = \int_{-\infty}^{\infty} p(x, y) dx$$

上式所给的 $p_X(x)$ 为 X 的边际密度函数， $p_Y(y)$ 为 Y 的边际密度函数。

我们来看下面这个例子。设二维随机变量 (X, Y) 的概率密度函数为

$$p(x, y) = \begin{cases} 1, & 0 < x < 1, |y| < 1 \\ 0, & \text{其他} \end{cases}$$

试求：边际概率密度函数 $p_X(x)$ 和 $p_Y(y)$

分析：首先我们可以看到 $p(x, y)$ 的非零区域。

对于 $p_X(x)$ ，当 $x \leq 0$ 或 $x \geq 1$ 时，有 $p_X(x) = 0$ ，而当 $0 < x < 1$ 时，有

$$p_X(x) = \int_{-x}^x dy = 2x$$

所以 X 的边际密度函数为

$$p_X(x) = \begin{cases} 2x, & 0 < x < 1 \\ 0, & \text{其他} \end{cases}$$

再求 $p_Y(y)$ 。

当 $y \leq -1$ ，或 $y \geq 1$ 时，有 $p_Y(y) = 0$ 。而当 $-1 < y < 0$ 时，有


$$p_Y(y) = \int_{-y}^1 dx = 1 + y$$

而当 $0 < y < 1$ 时，有

$$p_Y(y) = \int_y^1 dx = 1 - y$$

所以 Y 的边际密度函数为

$$p_Y(y) = \begin{cases} 1 + y, & -1 < y < 0 \\ 1 - y, & 0 < y < 1 \\ 0, & \text{其他} \end{cases}$$



3.2.4. 随机变量间的独立性

设 n 维随机变量 (X_1, X_2, \dots, X_n) 的联合分布函数 $F(x_1, x_2, \dots, x_n)$, $F_i(x_i)$ 为 X_i 的边际分布函数。如果对任意 n 个实数 x_1, x_2, \dots, x_n , 有

$$F(x_1, x_2, \dots, x_n) = \prod_{i=1}^n F_i(x_i), \text{ 则称 } X_1, X_2, \dots, X_n \text{ 相互独立。}$$

对于离散随机变量, 如果对其任意 n 个取值 x_1, x_2, \dots, x_n , 有

$$P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n) = \prod_{i=1}^n P(X_i = x_i), \text{ 则称 } X_1, X_2, \dots, X_n \text{ 相互独立。}$$

立。

对于连续随机变量, 如果对任意 n 个实数 x_1, x_2, \dots, x_n , 有

$$p(x_1, x_2, \dots, x_n) = \prod_{i=1}^n p_i(x_i), \text{ 则称 } X_1, X_2, \dots, X_n \text{ 相互独立。}$$

3.3. 多维随机变量的特征数

3.3.1. 数学期望

若二维随机变量 (X, Y) 的分布用联合分布列 $P(X = x, Y = y)$ 或用联合密度函数 $p(x, y)$ 表示, 则 $Z = g(X, Y)$ 的数学期望为

$$E(Z) = \begin{cases} \sum_i \sum_j g(x_i, y_j) P(X = x_i, Y = y_j), & \text{离散} \\ \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x, y) p(x, y) dx dy, & \text{连续} \end{cases}$$

还要指出, 在连续(离散)有:

- 当 $g(X, Y) = X$ 时, 可得 X 的数学期望为

$$E(X) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x p(x, y) dx dy = \int_{-\infty}^{\infty} x p_X(x) dx$$

- 当 $g(X, Y) = (X - E(X))^2$, 可得 X 的方差为

$$\begin{aligned} Var(X) &= E(X - E(X))^2 = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x - E(X))^2 p(x, y) dx dy \\ &= \int_{-\infty}^{\infty} (x - E(X))^2 p_X(x) dx \end{aligned}$$

类似的, 还可以给出 Y 的数学期望与反差的公式。

- $E(X + Y) = E(X) + E(Y)$
- 若随机变量 X 与 Y 相互独立, 则有 $E(XY) = E(X)E(Y)$
- 若随机变量 X 与 Y 相互独立, 则有 $Var(X \pm Y) = Var(X) + Var(Y)$

来个简单的例子。设一袋中装有 m 个颜色各不相同的球, 每次从中任取一个, 有放回的摸取 n 次, 以 X 表示在 n 次摸球中摸到球的不同颜色的数目, 求 $E(X)$ 。

分析: 直接写出 X 的分布列较为困难, 其原因在于: 若第 i 种颜色的球被取到过, 则此种颜色的球又可被取到过一次、二次…… n 次, 情况较多, 而其对立事件“第 i 种颜色的球没被取到过”的概率容易写出为 $P(\text{第 } i \text{ 种颜色的球在 } n \text{ 次摸球中一次也没被摸到}) = (1 - \frac{1}{m})^n$ 。令

$$X_i = \begin{cases} 1, & \text{第 } i \text{ 种颜色的球在 } n \text{ 次摸球中至少被摸到一次,} \\ 0, & \text{第 } i \text{ 种颜色的球在 } n \text{ 次摸球中一次也没被摸到,} \end{cases} \quad i = 1, 2, \dots, m$$

这些 X_i 相当于是计数器, 分别记录下第 i 种颜色的球是否被取到过, X 是取到过的不同颜色的总数, 所以 $X = \sum_{i=1}^m X_i$, 由 $P(X_i = 0) = (1 - \frac{1}{m})^n$ 。可得 $E(X_i) = P(X_i = 1) = 1 - (1 - \frac{1}{m})^n$ 。所以 $E(X) = mE(X_i) = m \left[1 - (1 - \frac{1}{m})^n \right]$ 。

3.3.2. 协方差

二维联合分布中除含各分量的边际分布外, 还含有两个分量间相互关系的信息, 描述这种相互关联程度的一个特征数就是协方差。定义如下: 设 (X, Y) 是一个二维随机变量, 若 $E[(X - E(X))(Y - E(Y))]$ 存在, 则称此数学期望为 X 与 Y 的协方差, 或称为 X 与 Y 的相关矩, 并记为 $Cov(X, Y) = E[(X - E(X))(Y - E(Y))]$, 特别的, 有 $Cov(X, X) = Var(X)$ 。

- 当 $Cov(X, Y) > 0$ 时, 称 X 与 Y 正相关, 这时两个偏差 $(X - E(X))$ 与 $(Y - E(Y))$ 有同时增加或同时减少的倾向。由于 $E(X)$, $E(Y)$ 为常数, 因此可以等价于 X 与 Y 有同时增加或减少的倾向, 这就是正相关。
- 当 $Cov(X, Y) < 0$ 时, 称 X 与 Y 负相关, 这时这就是有 X 增加而 Y 减少的倾向, 或有 Y 增加而 X 减少的倾向, 这就是负相关。
- 当 $Cov(X, Y) = 0$ 时, 称 X 与 Y 不相关, 注意不能等同于 X 与 Y 独立。

我们来看一个简单例子, 设二维随机变量 (X, Y) 的联合密度函数为

$$p(x, y) = \begin{cases} 3x, & 0 < y < x < 1, \\ 0, & \text{其他} \end{cases}$$

试求 $Cov(X, Y)$ 。

分析：

$$\begin{aligned} E(X) &= \int_0^1 \int_0^x x \cdot 3x dy dx = \frac{3}{4} \\ E(Y) &= \int_0^1 \int_0^x y \cdot 3x dy dx = \frac{3}{8} \\ E(XY) &= \int_0^1 \int_0^x xy \cdot 3x dy dx = \frac{3}{10} \\ Cov(X, Y) &= E(XY) - E(X)E(Y) = \frac{3}{10} - \frac{3}{4} \times \frac{3}{8} = \frac{3}{160} > 0 \end{aligned}$$

因此 X 与 Y 不相互独立。

3.3.3. 相关系数

正如方差与协方差一样，因为协方差是有量纲的量，所以引入新的概念——相关系数：设 (X, Y) 是一个二维随机变量，且 $Var(X) = \sigma_X^2 > 0, Var(Y) = \sigma_Y^2 > 0$ ，则

$$Corr(X, Y) = \frac{Cov(X, Y)}{\sqrt{Var(X)}\sqrt{Var(Y)}} = \frac{Cov(X, Y)}{\sigma_X \sigma_Y}$$

这里我们引入一个施瓦茨不等式：对任意二维随机变量 (X, Y) ，若 X 与 Y 的方差都存在，且记 $\sigma_X^2 = Var(X), \sigma_Y^2 = Var(Y)$ ，则有 $[Cov(X, Y)]^2 \leq \sigma_X^2 \sigma_Y^2$ 。证明如下：

不妨设 $\sigma_X^2 > 0$ ，因为当 $\sigma_X^2 = 0$ 时，说明 X 为常数，其与 Y 协方差为零，结论成立。若 $\sigma_X^2 > 0$ ，考虑如下二次函数：

$$g(t) = E[t(X - E(X)) + (Y - E(Y))]^2 = t^2 \sigma_X^2 + 2t \cdot Cov(X, Y) + \sigma_Y^2$$

由于上面的二次函数非负，而平方项系数 σ_X^2 为正，所以判别式 $\Delta \leq 0$ ，即 $[2Cov(X, Y)]^2 - 4\sigma_X^2 \sigma_Y^2 \leq 0$ ，移项后可得施瓦茨不等式。从该不等式可以得到 $-1 \leq Corr(X, Y) \leq 1$ 。

- $Corr(X, Y) = \pm 1$ 的充要条件是 X 与 Y 间几乎处处有线性关系，即存在 $a (\neq 0)$ 与 b ，使得 $P(Y = aX + b) = 1$ 。
- 相关系数 $Corr(X, Y)$ 刻画了 X 与 Y 之间的线性关系强弱，因此也常称其为“线性相关系数”。
- 若 $Corr(X, Y) = 0$ ，则称 X 与 Y 不相关。不相关是指 X 与 Y 之间没有线性关系，但 X 与 Y 之间可能有其他的函数关系，譬如平方关系、对数关

系等。

- 若 $\text{Corr}(X, Y) = 1$ ，则称 X 与 Y 完全正相关；若 $\text{Corr}(X, Y) = -1$ ，则称 X 与 Y 完全负相关。
- 若 $0 < |\text{Corr}(X, Y)| < 1$ ，则称 X 与 Y 有“一定程度”的线性关系。
 $|\text{Corr}(X, Y)|$ 越接近于 1，则线性相关程度越高； $|\text{Corr}(X, Y)|$ 越接近于 0，则线性相关程度越低。而协方差看不出这一点，若协方差很小，而其两个标准差 σ_X 和 σ_Y 也很小，则其比值就不一定很小。

✧ 4. 大数定律与中心极限定理

随机变量序列的收敛性有很多种，其中常用的是依概率收敛和按分布收敛。大数定律涉及的是一种依概率收敛，中心极限定理涉及到按分布收敛。接下来我们来介绍一下。

4.1. 随机变量序列的两种收敛性

4.1.1. 依概率收敛

在第一部分我们使用频率确定概率时，我们提出“概率是频率的稳定值”，或“频率稳定于概率”，现在我们来解释“稳定”的含义。

设有一大批产品，其不合格品率为 p 。现一个接一个地检查产品的合格性，记前 n 次检查发现 S_n 个不合格品，而 $v_n = \frac{S_n}{n}$ 为不合格品出现的频率。当检查继续下去，我们就发现频率序列 $\{v_n\}$ 有如下两个现象：

(1) 频率 v_n 对概率 p 的绝对偏差 $|v_n - p|$ 将随 n 增大而呈现逐渐减小的趋势，但无法说它收敛于零。

(2) 由于频率的随机性，绝对偏差 $|v_n - p|$ 时大时小。虽然我们无法排除大偏差发生的可能性，但随着 n 不断增大，大偏差发生的可能性会越来越小。这是一种新的极限概念。

用数学式子表示如下：对任意给定的 $\varepsilon > 0$ ，事件 $\{|v_n - p| \geq \varepsilon\}$ 出现了就认为大偏差发生了，而大偏差发生的可能性越来越小，相当于 $P(|v_n - p| \geq \varepsilon) \rightarrow 0 (n \rightarrow \infty)$ ，这时就可以称序列 $\{v_n\}$ 依概率收敛，这就是“频率稳定于概率”。

下面给出一般的随机变量序列 $\{X_n\}$ 依概率收敛于一个随机变量 X 的定义：设 $\{X_n\}$ 为随机变量序列， X 为以随机变量，如果对任意的 $\varepsilon > 0$ ，有 $P(|X_n - X| \geq \varepsilon) \rightarrow 0 (n \rightarrow \infty)$ 。则称序列 $\{X_n\}$ 依概率收敛于 X ，记作 $X_n \xrightarrow{P} X$ 。其含义为： X_n 对 X 的绝对偏差不小于任一给定量的可能性将随着 n 增大而减小。或者说，绝对偏差 $|X_n - X|$ 小于任一给定量的可能性将随着 n 增大而越来越接近1，即 $P(|X_n - X| < \varepsilon) \rightarrow 1 (n \rightarrow \infty)$ 。特别当 X 为退化分布时，即 $P(X = c) = 1$ ，则称序列 $\{X_n\}$ 依概率收敛于 c ，记作 $X_n \xrightarrow{P} c$ 。

4.1.2. 按分布收敛

依概率收敛，描述的是当 $n \rightarrow \infty$ 时，随机变量序列越来越接近（趋近于）某个确定的随机变量的概率接近于1。我们知道随机变量的分布函数全面描述了随机变量的统计规律，如何来定义 $\{F_n(x)\}$ 的收敛性呢？可以猜想：对于所有的 x ，有 $F_n(x) \rightarrow F(x) (n \rightarrow \infty)$ 呢？这其实就是按分布收敛，具体来说，对于随机变量 X, X_1, X_2, \dots 的分布函数分别为 $F(x), F_1(x), F_2(x), \dots$ 。若对 $F(x)$ 的任一连续点 x ，都有 $\lim_{n \rightarrow \infty} F_n(x) = F(x)$ ，则称 $\{F_n(x)\}$ 弱收敛于 $F(x)$ ，记作 $F_n(x) \xrightarrow{W} F(x)$ ，也称相应的随机变量序列 $\{X_n\}$ 按分布收敛于 X ，记作 $X_n \xrightarrow{L} X$ 。

4.2. 大数定律

4.2.1. 伯努利大数定律

记 S_n 为 n 重伯努利试验中事件 A 出现的次数，称 $\frac{S_n}{n}$ 为事件 A 出现的频率。如果记一次试验中 A 发生的概率为 p ，则 S_n 服从二项分布 $b(n, p)$ ，因此频率 $\frac{S_n}{n}$ 的数学期望和方差分别为

$$E\left(\frac{S_n}{n}\right) = p, \quad Var\left(\frac{S_n}{n}\right) = \frac{p(1-p)}{n}$$

对任意 $\varepsilon > 0$ ，有 $\lim_{n \rightarrow \infty} P\left(\left|\frac{S_n}{n} - p\right| < \varepsilon\right) = 1$ 。

伯努利大数定律说明：随着 n 的增大，事件 A 发生的概率 $\frac{S_n}{n}$ 与其概率 p 的偏差 $\left|\frac{S_n}{n} - p\right|$ 大于预先给定的精度 ε 的可能性愈来愈小，这就是频率稳定于概率的含义。

下面我们来看一个例子，使用蒙特卡罗法计算定积分。设 $0 \leq f(x) \leq 1$ ，求 $f(x)$ 在区间 $[0, 1]$ 上的积分值 $\int_0^1 f(x)dx$ 。

设二维随机变量 (X, Y) 服从正方形 $\{0 \leq x \leq 1, 0 \leq y \leq 1\}$ 的均匀分布，则可知 $X \sim U(0, 1)$, $Y \sim U(0, 1)$ ，且 X 与 Y 相互独立，记事件 $A = \{Y \leq f(X)\}$ ，则有

$$P(A) = P(Y \leq f(X)) = \int_0^1 \int_0^{f(x)} dy dx = \int_0^1 f(x) dx = J$$


也就是定积分的值就是事件 A 的概率。由伯努利大数定律，我们可以使用重复试验中 A 出现的频率作为 p 的估计值。这种求解定积分的方法称为随机投点法。

下面我们使用蒙特卡洛方法得到 A 出现的频率：

- 先产生 $(0, 1)$ 上均匀分布的 $2n$ 个随机数，组成 n 对随机数 (x_i, y_i) , $i = 1, 2, \dots, n$ ， n 可以取很大的数
- 对 n 对数据 (x_i, y_i) ，记录满足如下不等式 $y_i \leq f(x_i)$ 的次数，这就是事件 A 发生的频数 S_n ，由此可以计算事件 A 发生的频率 $\frac{S_n}{n}$ ，则积分 $\approx \frac{S_n}{n}$ 。

我们取 $f(x) = x^3$ ，尝试使用蒙特卡洛投点法计算积分，代码如下：

```
1 from scipy.stats import uniform
2 # 蒙特卡洛积分计算的原理：
3 x_arr = np.linspace(0,1,1000)
4 x_n = uniform.rvs(size = 100) # 随机选择n个x随机数
5 y_n = uniform.rvs(size = 100) # 随机选择n个y随机数
6 plt.stackplot(x_arr, x_arr ** 3, alpha=0.5, color="skyblue") # 堆积面积图
7 plt.scatter(x_n, y_n)
8 plt.text(1.0, 1.0, r'$y=x^3$')
9 plt.show()
```



```

1 def montecarlo_method(n):
2     x_n = uniform.rvs(size = n) # 随机选择n个x随机数
3     y_n = uniform.rvs(size = n) # 随机选择n个y随机数
4     fx = x_n ** 3
5     sn = np.sum([y_n[i] <= fx[i] for i in range(n)])
6     return sn / n
7
8 x = symbols("x")
9 print(f'y=x**3在[0,1]的定积分为: {integrate(x ** 3, (x,0, 1))}')
10 for n in [10, 100, 1000, 10000, 100000]:
11     print(f'蒙特卡洛法模拟{n}次得到的积分近似值:
        {montecarlo_method(n)}')

```

$y=x^3$ 在 $[0,1]$ 的定积分为: $1/4$
 蒙特卡洛法模拟10次得到的积分近似值: 0.2
 蒙特卡洛法模拟100次得到的积分近似值: 0.23
 蒙特卡洛法模拟1000次得到的积分近似值: 0.271
 蒙特卡洛法模拟10000次得到的积分近似值: 0.2535
 蒙特卡洛法模拟100000次得到的积分近似值: 0.25243

4.2.2. 辛钦大数定律

设 $\{X_n\}$ 为一独立同分布的随机变量序列，若 X_i 的数学期望存在，则 $\{X_n\}$ 服从大数定律，即对任意的 $\varepsilon > 0$,

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n E(X_i)\right| < \varepsilon\right) = 1$$

成立。

对于独立同分布且具有相同均值 μ 的随机变量 X , X_1, X_2, \dots, X_n , 当 n 很大时，它们的算术平均数 $\frac{1}{n} \sum_{i=1}^n X_i$ 很接近于 μ 。也就是说可以使用样本的均值去估计总体均值。

由辛钦大数定律我们可以得出，如果 $\{X_n\}$ 为某一独立同分布的随机变量序列，且 $E(|X_i|^k)$ 存在，其中 k 为正整数，则 $\{X_n^k\}$ 服从大数定律，这就是说，我们其实可以将 $\frac{1}{n} \sum_{i=1}^n X_i^k$ 作为 $E(X_i^k)$ 的近似值。

因此，我们也可以用平均值法下的蒙特卡洛方法计算定积分 $J = \int_0^1 f(x)dx$ 。设随机变量 $X \sim U(0,1)$ ，则 $Y = f(x)$ 的数学期望为 $E(f(x)) = \int_0^1 f(x)dx$ 。由辛钦大数定律，可以用 $f(X)$ 的观察值的平均取估计 $f(X)$ 的数学期望的值。具体做法如下：

- 产生 n 个均匀分布的随机数 $x_i, i = 1, 2, \dots, n$

- 对每个 x_i 计算 $f(x_i)$ ，最后得到 $J \approx \frac{1}{n} \sum_{i=1}^n f(x_i)$

代码如下所示：

```
1 def montecarlo_method_mean(n):
2     x_n = uniform.rvs(size=n)
3     fx = x_n ** 3
4     return np.mean(fx)
5
6 x = symbols("x")
7 print(f'y=x**3在[0,1]的定积分为: {integrate(x ** 3, (x,0, 1))}')
8 for n in [10, 100, 1000, 10000, 100000]:
9     print(f'蒙特卡洛法(平均值法)模拟{n}次得到的积分近似值:
    {montecarlo_method_mean(n)}')
```

y=x**3在[0,1]的定积分为: 1/4

蒙特卡洛法(平均值法)模拟10次得到的积分近似值: 0.35391983862405274

蒙特卡洛法(平均值法)模拟100次得到的积分近似值: 0.2708569337984175

蒙特卡洛法(平均值法)模拟1000次得到的积分近似值: 0.2665572316943115

蒙特卡洛法(平均值法)模拟10000次得到的积分近似值: 0.24909670562827538

蒙特卡洛法(平均值法)模拟100000次得到的积分近似值: 0.25138494129256245

4.3. 中心极限定理

大数定律讨论的是在什么条件下，随机变量序列的算术平均依概率收敛到其均值的算术平均，现在我们讨论在什么条件下，独立随机变量和 $Y_n = \sum_{i=1}^n X_i$ 的分布函数会收敛于正态分布。

我们先给出一个独立随机变量和的例子。操作者在机床上加工机械轴，由于加工时会受到一些随机因素的影响，因此会每个机械轴的直径产生误差，若将这个误差记为 Y_n ，那么随机变量 Y_n 可以看作很多微小的随机波动 X_1, X_2, \dots, X_n 之和，即 $Y_n = X_1 + X_2 + \dots + X_n$ 。这里的 n 是很大的，当 $n \rightarrow \infty$ 时， Y_n 的分布是什么？

我们尝试用正态分布、均匀分布、指数分布、泊松分布、0-1分布来模拟


4.3.1. 正态分布

```
1 # 模拟n个正态分布的和的分布
2 from scipy.stats import norm
3
4 def plot_hist(arr, ax, n):
5     ax.hist(arr)
6     ax.set_title("n = "+str(n))
```

```

7     ax.set_xlabel("x")
8     ax.set_ylabel("p (x)")
9
10    def norm_sum_n(n):
11        num_samples = 1000
12        arr = np.zeros(num_samples)
13        for i in range(n):
14            mu = 0
15            sigma2 = np.random.rand()
16            err_arr = norm.rvs(mu, sigma2, num_samples)
17            arr += err_arr
18        return arr
19
20
21    fig, axes = plt.subplots(2, 3, figsize=(12, 9))
22    for i, n in enumerate([2, 10, 100, 1000, 10000, 100000]):
23        arr = norm_sum_n(n)
24        plot_hist(arr, axes[i // 3][i % 3], n)

```



4.3.2. 均匀分布

```


1    # 模拟n个均匀分布的求和分布
2    from scipy.stats import uniform
3
4    def plot_hist(arr, ax, n):
5        ax.hist(arr)

```

```

6     ax.set_title("n = "+str(n))
7     ax.set_xlabel("x")
8     ax.set_ylabel("p (x)")
9
10    def uniform_sum_n(n):
11        num_samples = 1000
12        arr = np.zeros(num_samples)
13        for i in range(n):
14            err_arr = uniform.rvs(size=num_samples)
15            arr += err_arr
16        return arr
17
18
19    fig, axes = plt.subplots(2, 3, figsize=(12, 9))
20    for i, n in enumerate([2, 10, 100, 1000, 10000, 100000]):
21        arr = uniform_sum_n(n)
22        plot_hist(arr, axes[i // 3][i % 3], n)

```



4.3.3. 指数分布

```


1    # 模拟n个指数分布的和的分布
2    from scipy.stats import expon
3
4    def plot_hist(arr, ax, n):
5        ax.hist(arr)
6        ax.set_title("n = "+str(n))
7        ax.set_xlabel("x")

```

```

8     ax.set_ylabel("p (x)")
9
10    def expon_sum_n(n):
11        num_samples = 1000
12        arr = np.zeros(num_samples)
13        for i in range(n):
14            err_arr = expon.rvs(size=num_samples)
15            arr += err_arr
16        return arr
17
18
19    fig, axes = plt.subplots(2, 3, figsize=(12, 9))
20    for i, n in enumerate([2, 10, 100, 1000, 10000, 100000]):
21        arr = expon_sum_n(n)
22        plot_hist(arr, axes[i // 3][i % 3], n)

```



4.3.4. 泊松分布

```


1    # 模拟n个泊松分布的和的分布
2    from scipy.stats import poisson
3
4    def plot_hist(arr, ax, n):
5        ax.hist(arr)
6        ax.set_title("n = "+str(n))
7        ax.set_xlabel("x")
8        ax.set_ylabel("p (x)")
9

```

```

10 def poisson_sum_n(n):
11     num_samples = 1000
12     arr = np.zeros(num_samples)
13     for i in range(n):
14         err_arr = poisson.rvs(mu=1.0, size=num_samples)
15         arr += err_arr
16     return arr
17
18
19 fig, axes = plt.subplots(2, 3, figsize=(12, 9))
20 for i, n in enumerate([2, 10, 100, 1000, 10000, 100000]):
21     arr = poisson_sum_n(n)
22     plot_hist(arr, axes[i // 3][i % 3], n)

```



4.3.5. 0-1分布

```


1  # 模拟n个0-1分布的的和的分布
2  from scipy.stats import bernoulli
3
4  def plot_hist(arr, ax, n):
5      ax.hist(arr)
6      ax.set_title("n = "+str(n))
7      ax.set_xlabel("x")
8      ax.set_ylabel("p (x)")
9
10 def bernoulli_sum_n(n):
11     num_samples = 1000

```

```

12     arr = np.zeros(num_samples)
13     for i in range(n):
14         err_arr = bernoulli.rvs(p=0.5, size=num_samples)
15         arr += err_arr
16     return arr
17
18
19 fig, axes = plt.subplots(2, 3, figsize=(12, 9))
20 for i, n in enumerate([2, 10, 100, 1000, 10000, 100000]):
21     arr = bernoulli_sum_n(n)
22     plot_hist(arr, axes[i // 3][i % 3], n)

```



以上模拟说明：假设 $\{X_n\}$ 独立同分布、方差存在，不管原来的分布是什么，只要 n 充分大，就可以用正态分布去逼近随机变量和的分布，这就是中心极限定理。

✧ 5. 数学建模综合案例分析：投资组合风险分析

GitModel公司是一家专业的投资银行，志在帮助客户更好地管理资产。客户手头上有一笔100万的资金，希望将这笔钱投入股票市场进行投资理财，投资人看中了两个股票A、B，股票分析师通过对股票A、B的历史数据分析发现：股票A的平均收益近似服从 $N(0.1, 0.01)$ ，股票B的平均收益近似服从 $N(0.3, 0.04)$ 。现在客户希望通过

分析得出投资股票A、B的最佳组合（在预期收益确定情况下最小风险时，需要投资A、B的份额）。

分析：首先，我们先来分析投资组合的收益应该如何计算：设A、B的投资收益率为随机变量 X 、 Y ，因此 $X \sim N(0.1, 0.01)$ ， $Y \sim N(0.3, 0.04)$ 。设 x_1 为投资A的份额， $y_1 = 1 - x_1$ 为投资B的份额，因此投资组合的收益率为： $Z = x_1 * X + y_1 * Y$ ，投资组合的平均收益率为： $E(Z) = x_1 * E(X) + y_1 * E(Y)$ 。

接下来，我们来分析投资组合的风险应该如何计算：何为风险，最简单来说就是收益的不确定性，如果收益是确定且固定的，就无所谓的风险可言。根据对风险的直观描述，我们可以定义风险为收益率的方差，因此：股票A的风险为 $\sigma_x^2 = 0.01$ ，股票B的风险为 $\sigma_y^2 = 0.04$ ，而投资组合的风险为

$$\begin{aligned} \text{Var}(Z) &= \text{Var}(x_1 * X + y_1 * Y) \\ &= x_1^2 \text{Var}(X) + y_1^2 \text{Var}(Y) + 2x_1y_1 \text{Cov}(X, Y) \end{aligned}$$

因此，最佳的投资组合应该是风险最小时的投资组合，即：

$$\begin{aligned} \min \quad & \text{Var}(Z) \\ = \min \quad & x_1^2 \text{Var}(X) + y_1^2 \text{Var}(Y) + 2x_1y_1 \text{Cov}(X, Y) \\ = \quad & \frac{d(\text{Var}(Z))}{d(x_1)} = 0 \end{aligned}$$

我们尝试用代码来求解，这里我们取相关系数 $\rho = 0.4$ ：

```
1  from sympy import *
2  x = symbols('x')
3  y = symbols('y')
4  y = 1-x
5  ## 请根据var_Z的定义写出相应的公式代码
6  var_z = x * x * 0.01 + y * y * 0.04 + 2 * x * y * 0.4 * 0.1 * 0.2
7  ## 一阶导数=0
8  derivation_var_z = diff(var_z, x)
9  stagnation = solve(derivation_var_z, x)
10 print(stagnation)
```

[0.941176470588235]

因此，根据风险最小化原则，应该投资A股票 $10w \times 0.94$ 元，而投资B股票 $10w \times 0.06$ 元。

6. 小结

这次的打卡内容相当的充实，也花费了不少时间。虽然已经对教材和教程内容做了一定的精简，但是篇幅还是相当大，当然本篇文章也只是给帮助大家回顾概率论所学知识，欢迎小伙伴一起交流~